

Проект с ML-решением: **Общественный сентимент и эволюция вакцинационного дискурса на платформе Pikabu**

Задача

Исследовательская задача: понять, как в русскоязычном сегменте интернета устроена дискуссия о вакцинации в период COVID-19 и после него. Три исследовательских вопроса:

- 1) Какие темы возникают в обсуждениях вакцинации на платформе Pikabu и как они различаются по вовлеченности пользователей?
- 2) Как распределяется эмоциональная окраска (сентимент) внутри этих тем?
- 3) Как сентимент меняется во времени с 2020 по 2025 год?

Почему именно Pikabu?

Pikabu - площадка, устроенная по логике Reddit: посты, ветки комментариев, голосование и ранжирование. В отличие от платформ, тесно связанных с официальными медиа, Pikabu даёт доступ к спонтанной, свободной дискуссии. При этом Pikabu почти не изучался *методами NLP* в контексте вакцинного дискурса, что и составляло исследовательский пробел.

Продуктовая цель: создать инструмент мониторинга, который в режиме, близком к реальному времени, показывает тон и структуру общественной дискуссии по вакцинам и препаратам.

Почему это важно

С исследовательской точки зрения: социальные сети - основной источник медицинской информации. Структура онлайн-обсуждений влияет на индивидуальные установки и общественное здоровье: если пользователь сталкивается преимущественно с недоверием и враждебной коммуникацией, это может снижать доверие к традиционной медицине.

С продуктовой точки зрения: Система мониторинга общественного мнения, которая позволит понимать, как реагирует аудитория в периоды эпидемий, вывода на рынок новой вакцины или препарата, изменение политики здравоохранения. Система поможет, правильно выстроить кампанию, на какие

опасения ответить в первую очередь и стоит ли корректировать саму стратегию вывода продукта. Без такой обратной связи коммуникация и анализ строится вслепую.

Целевая аудитория: фарм компании, выводящие продукты на рынок, государственные учреждения, отвечающих за политику здравоохранения.

Данные

Корпус с Pikabu за период 2020-2026 годов. Отбор постов строился на списке русскоязычных ключевых слов, связанных с вакцинацией.

Данные для каждого поста: **ID, заголовок, URL, дата публикации, лайки, дизлайки, число комментариев, текст и ключевое слово** извлекались с помощью Python. Итоговая структура «пост - комментарии», где комментарии привязаны к родительскому посту через post_id. Итоговый корпус - **5 298** постов и **159 062** комментария.

Методы

Этапы работы:

1. Тематическое моделирование постов методами: Latent Dirichlet Allocation (LDA) и BERTopic.
2. Анализ сентимента комментариев трансформерной русскоязычной моделью (rubert-conversational) по трем категориям: негативный, нейтральный, позитивный. Расчет взвешенного показателя сентимента на основе уверенности модели, позволяющий сравнивать средний тон между темами и годами.
3. Статистическое сравнение. Насколько значимо темы отличаются по эмоциональной окраске и вовлеченности и насколько значимо по эмоциональности дискуссии различаются года.
4. [Прототип дашборда](#) развернутого как публичное веб-приложение на Streamlit; в текущей MVP-версии демонстрация идет на собранном корпусе. Планируется улучшения архитектуры для автоматического обновления дашборда и расширения списка источников.

Результаты

Исследовательский результат.

Главный вывод: темы «Личный опыт и здравоохранение» и «Политика и государство» вызывают самую сильную дискуссию, они одновременно собирают максимальную вовлеченность и оказываются самыми негативными.

Кроме того, исследование подтверждает валидность Pikabu как источника для мониторинга:

- 1) Сбалансированный дискурс: 72,6% комментариев нейтральны, 24,6% негативны и 2,7% позитивны.
- 2) Не поверхностная аудитория: устойчиво выделяются кластеры «Иммунология и наука» и «Лечение и медицина», где обсуждается сама наука о вирусах и препаратах.
- 3) Дискуссия стабильна во времени, что указывает на сформировавшееся ядро аудитории.

Продуктовый результат. [Прототип интерактивного веб-приложения](#)

визуализирует ключевые результаты исследования: общий тон дискуссии, распределение постов и сентимент по темам, динамику сентимента и список наиболее обсуждаемых постов.

Дашборд превращает разовое исследование в воспроизводимый инструмент мониторинга. Для фармацевтических компаний и государственных учреждений это способ быстро увидеть, как аудитория реагирует на новую вакцину или препарат: какие темы доминируют, вокруг каких сюжетов концентрируется негатив и наибольшая вовлеченность, меняется ли тон со временем. Вместо поверхностных оценок пользователь получает разложенную по темам и времени картину, на которую можно опереться при выстраивании коммуникационной стратегии - например, усиливать разъяснение там, где негатив связан с личным опытом и здоровьем, и отдельно работать с недоверием к институтам в политически окрашенных темах.